

# AlphaTensor

Discovering faster matrix multiplication algorithms with reinforcement learning

小组：李致远、冯文喆、魏睿、宋泽顷、周启民

同济大学物理科学与工程学院

2025 年 12 月 11 日



## ① 背景介绍

## ② 核心原理

## ③ 实验结果

## ④ 总结展望



## ① 背景介绍

## ② 核心原理

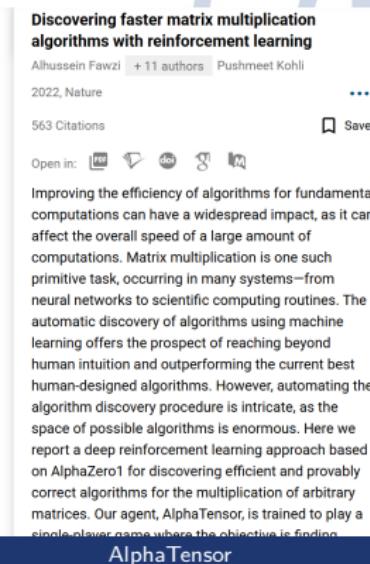
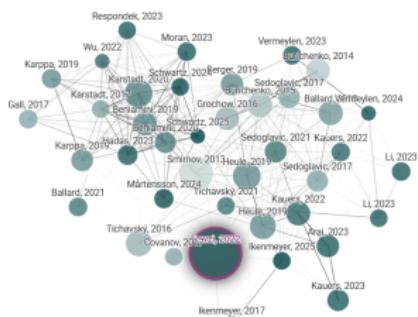
## ③ 实验结果

## ④ 总结展望



# 为什么选择这篇文章？

- **本文作者**, 是 Google DeepMind 团队的研究员。
    - DeepMind 是人工智能领域的领军机构 (AlphaGo、AlphaFold 等), DeepMind 团队联合创始人获得 2024 诺贝尔化学奖。
  - **学术影响力**, 论文发表在**Nature(2022)**, 引用次数超过 **500**, github star 超过 **2800**。



# AlphaTensor 概述

## 核心理念

“Discovering faster matrix multiplication algorithms with reinforcement learning” 利用强化学习对矩阵乘法流程进行自动设计。

- **问题描述**: 将一个矩阵乘法与一个张量  $T_n = \sum_{r=1}^R u^{(r)} \otimes v^{(r)} \otimes w^{(r)}$  构建映射。
- **解法思路**: 沿用 alphazero 强化学习的基本架构, 通过多次自我博弈, 找到矩阵  $T_n$  的最小的低秩分解。
- **解法细节**: 基于 transformer 架构。对矩阵  $T_n$  提取嵌入特征后, 用策略头与价值头计算下一步的秩-1 分解与得分。使用 MCTS 剪枝搜索, 产出一个完整的低秩分解。

# 为什么关注矩阵乘法？

- **核心地位**, 矩阵乘法是深度学习（全连接层、Conv 层、transformer 层）和科学计算的基石。
- **优化维度**
  - *System* 角度：向量化、访存优化（Cache 命中）、并行计算。
  - *Math* 角度（本文研究方向）：因为乘法开销  $\gg$  加法开销，减少数值乘法的计算次数能显著提升性能。

## Strassen 算法的启示 (1969)

对于  $2 \times 2$  矩阵乘法：

- **朴素算法**：需要 8 次乘法 ( $O(N^3)$ )。
- **Strassen 算法**：只需要 7 次乘法 ( $O(N^{2.807})$ )。

这意味着通过改变算法流程，可以在数学层面实现加速。

# Strassen 算法的启示

- 硬件层面的动机：

- 可以简单理解为，乘法器就是由加法器堆叠起来的。
- 执行乘法的时间是加法的约 **3.5 倍**。
- 减少乘法次数 = 实际性能提升

- Strassen 的贡献 (1969)：

- 将  $2 \times 2$  矩阵乘法从 8 次降至 7 次，大矩阵可以递归拆分为  $2 \times 2$  子矩阵。
- 复杂度：  
 $O(N^3) \rightarrow O(N^{2.807})$

$$\begin{bmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{bmatrix} \times \begin{bmatrix} b_{1,1} & b_{1,2} \\ b_{2,1} & b_{2,2} \end{bmatrix} = \begin{bmatrix} c_{1,1} & c_{1,2} \\ c_{2,1} & c_{2,2} \end{bmatrix}$$

Standard algorithm

Strassen's algorithm

$$h_1 = a_{1,1} b_{1,1}$$

$$h_2 = a_{1,1} b_{1,2}$$

$$h_3 = a_{1,2} b_{2,1}$$

$$h_4 = a_{1,2} b_{2,2}$$

$$h_5 = a_{2,1} b_{1,1}$$

$$h_6 = a_{2,1} b_{1,2}$$

$$h_7 = a_{2,2} b_{1,1}$$

$$h_8 = a_{2,2} b_{1,2}$$

$$h_1 = (a_{1,1} + a_{2,1})(b_{1,1} + b_{2,1})$$

$$h_2 = (a_{1,1} + a_{2,1})b_{1,2}$$

$$h_3 = a_{1,1}(b_{1,2} - b_{2,2})$$

$$h_4 = a_{2,2}(-b_{1,1} + b_{2,1})$$

$$h_5 = (a_{1,1} + a_{1,2})b_{2,2}$$

$$h_6 = (-a_{1,1} + a_{2,1})(b_{1,1} + b_{1,2})$$

$$h_7 = (a_{1,2} - a_{2,2})(b_{2,1} + b_{2,2})$$

$$c_{1,1} = h_1 + h_3$$

$$c_{1,2} = h_2 + h_4$$

$$c_{2,1} = h_5 + h_7$$

$$c_{2,2} = h_6 + h_8$$

$$c_{1,1} = h_1 + h_4 - h_5 + h_7$$

$$c_{1,2} = h_3 + h_5$$

$$c_{2,1} = h_2 + h_4$$

$$c_{2,2} = h_1 - h_5 + h_3 + h_6$$

# AlphaTensor 概述

## 核心理念

“Discovering faster matrix multiplication algorithms with reinforcement learning” 利用强化学习对矩阵乘法流程进行自动设计。

- **问题描述**: 将一个矩阵乘法与一个张量  $T_n = \sum_{r=1}^R u^{(r)} \otimes v^{(r)} \otimes w^{(r)}$  构建映射。
- **解法思路**: 沿用 alphazero 强化学习的基本架构, 通过多次自我博弈, 找到矩阵  $T_n$  的最小的低秩分解。
- **解法细节**: 基于 transformer 架构。对矩阵  $T_n$  提取嵌入特征后, 用策略头与价值头计算下一步的秩-1 分解与得分。使用 MCTS 剪枝搜索, 产出一个完整的低秩分解。

## ① 背景介绍

## ② 核心原理

## ③ 实验结果

## ④ 总结展望



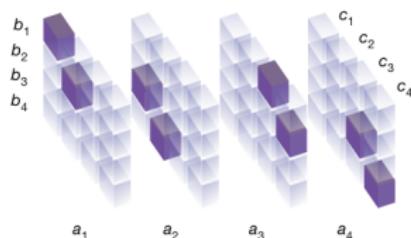
# 建立映射：直观解释

以  $2 \times 2 \times 2$  矩阵为例

- 矩阵结构：列代表乘法数，行代表最终矩阵元素数
- 三个矩阵的含义：
  - 绿色矩阵 ( $U$ )：第一个乘数的线性组合
  - 紫色矩阵 ( $V$ )：第二个乘数的线性组合
  - 橙色矩阵 ( $W$ )：结果矩阵的线性组合

**a**

$$\begin{pmatrix} c_1 & c_2 \\ c_3 & c_4 \end{pmatrix} = \begin{pmatrix} a_1 & a_2 \\ a_3 & a_4 \end{pmatrix} \cdot \begin{pmatrix} b_1 & b_2 \\ b_3 & b_4 \end{pmatrix}$$

**b**

$$m_1 = (a_1 + a_4)(b_1 + b_4)$$

$$m_2 = (a_3 + a_4)b_1$$

$$m_3 = a_1(b_2 - b_4)$$

$$m_4 = a_4(b_3 - b_1)$$

$$m_5 = (a_1 + a_2)b_4$$

$$m_6 = (a_3 - a_1)(b_1 + b_2)$$

$$m_7 = (a_2 - a_4)(b_3 + b_4)$$

$$c_1 = m_1 + m_4 - m_5 + m_7$$

$$c_2 = m_3 + m_5$$

$$c_3 = m_2 + m_4$$

$$c_4 = m_1 - m_2 + m_3 + m_6$$

**c**

$$U = \begin{pmatrix} 1 & 0 & 1 & 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & -1 \end{pmatrix}$$

$$V = \begin{pmatrix} 1 & 1 & 0 & -1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & -1 & 0 & 1 & 0 & 1 \end{pmatrix}$$

$$W = \begin{pmatrix} 1 & 0 & 0 & 1 & -1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & -1 & 1 & 0 & 0 & 1 & 0 \end{pmatrix}$$

# 建立映射：搜索空间的构建

AlphaTensor 将寻找算法抽象为寻找 3D 张量分解的过程。

对应关系 ①：矩阵乘定义  $\leftrightarrow$  表征张量  $T_n$

- 一种尺寸的矩阵乘法定义（如  $2 \times 2$ ）唯一对应一个三维张量  $T_n$ 。张量中的元素为  $\{-2, -1, 0, 1, 2\}$ ，代表结果矩阵中位置的值由哪些输入元素相乘得到。

对应关系 ②：低秩分解  $\leftrightarrow$  算法流程

- 表征张量的 **秩 (Rank)** = 算法所需的 **乘法次数**。
- 将  $T_n$  分解为  $R$  个秩-1 张量的和， $T_n$  的大小为  $n^2 \times n^2 \times n^2$ ，记为  $S \times S \times S$ ，

$$T_n = \sum_{r=1}^R u^{(r)} \otimes v^{(r)} \otimes w^{(r)}$$

# 强化学习建模

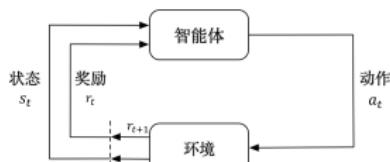
- **目标**, 用尽可能少的步数 (秩-1 张量) 将初始张量  $T_n$  减为零张量。
  - **状态 (State)**, 当前剩余的张量  $S_t$  (初始为  $T_n$ )。
  - **动作 (Action)**, 选择三个向量  $u, v, w$  构成一个秩-1 张量。
  - **动作选择**, 通过蒙特卡洛树搜索 (MCTS), 选择一个最优的动作。
  - **状态更新**,  $S_{t+1} \leftarrow S_t - u \otimes v \otimes w$

## 奖励函数 (Reward)

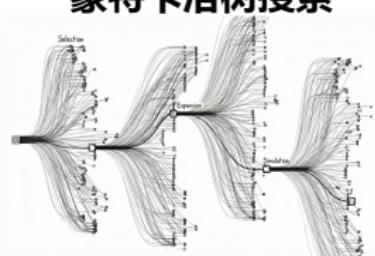
- 每走一步,  $Reward = -1$  (鼓励更少步数)。
  - 若步骤超限未归零, 施加额外惩罚 (与剩余张量的秩相关)。
  - 加入硬件运行时延时作为负奖励 (针对特定硬件优化)。

# 强化学习架构

## 强化学习典型架构

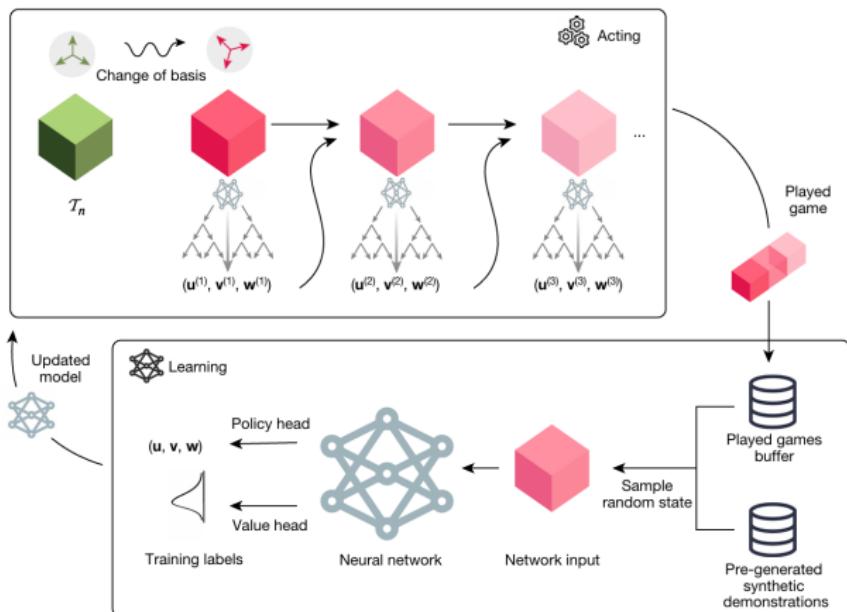


## 蒙特卡洛树搜索



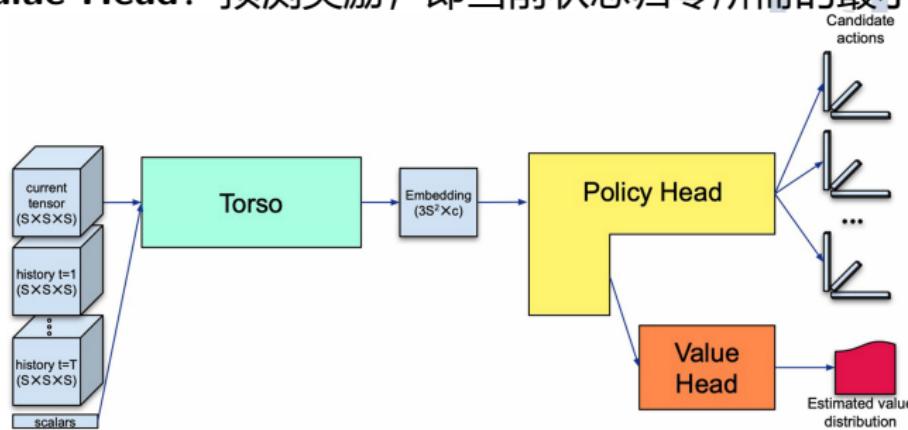
- 环境/状态:  $T_n$
- 动作: 策略头
- 奖励: 价值头

## AlphaTensor 架构

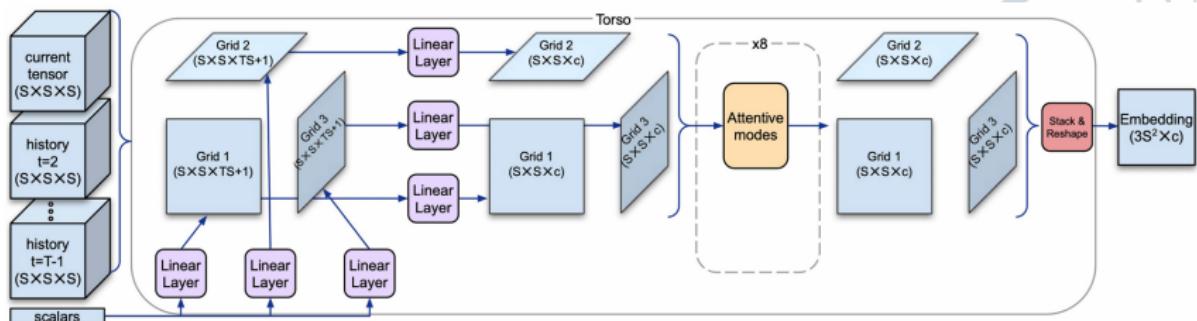


# 网络架构与搜索算法

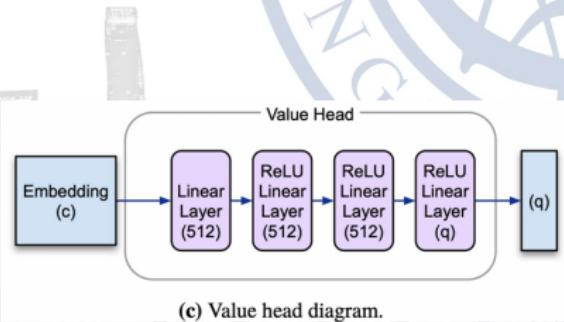
- **MCTS**: 用于规划下一步动作，平衡探索 (Explore) 与利用 (Exploit)
- **Torso**: 当前时间  $T$ , 提取张量  $T \times T_n$  的嵌入特征
- **Policy Head**: 依次输出  $k$  个令牌，与  $u \otimes v \otimes w$  等价，每个 token 的维度为  $d$ , 其中  $k \times d = 3S$
- **Value Head**: 预测奖励，即当前状态归零所需的最小步数



# AlphaTensor 架构细节 1

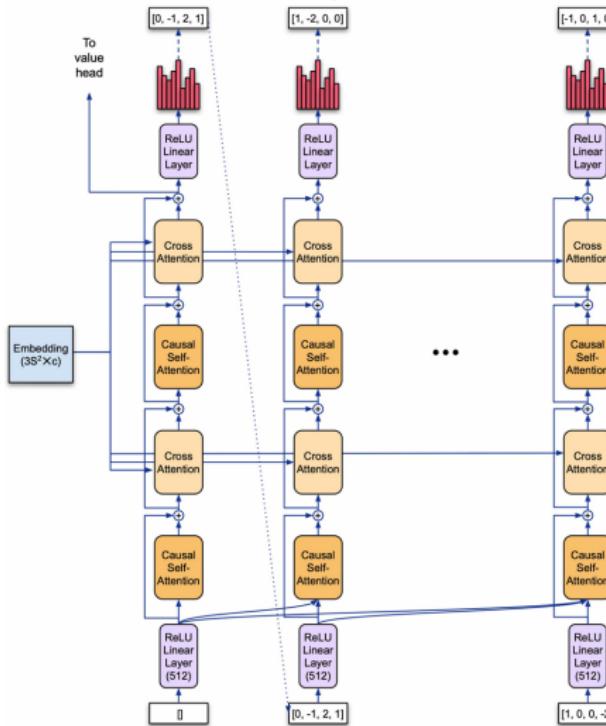


- **Torso**, 输入历史张量  $T \times S \times S \times S$ ,  
输出嵌入特征  $3S^2 \times c$
- **Value Head**, 输入小向量  $1 \times c$ ,  
输出小向量  $1 \times q$
- **超参数**,  $c = 512, q = 128$



AlphaTensor 架构细节 2

- **Policy Head**, 输入零向量  $1 \times d$  与嵌入特征  $3S^2 \times c$ , 输出令牌  $1 \times d$ , 重复  $k$  次
  - **超参数**,  
 $d = S, k = 3, c = 512$



**(b)** Policy head diagram. Blocks in the same row share the learning weights.

## ① 背景介绍

## ② 核心原理

## ③ 实验结果

## ④ 总结展望



# 理论突破：发现更优的秩

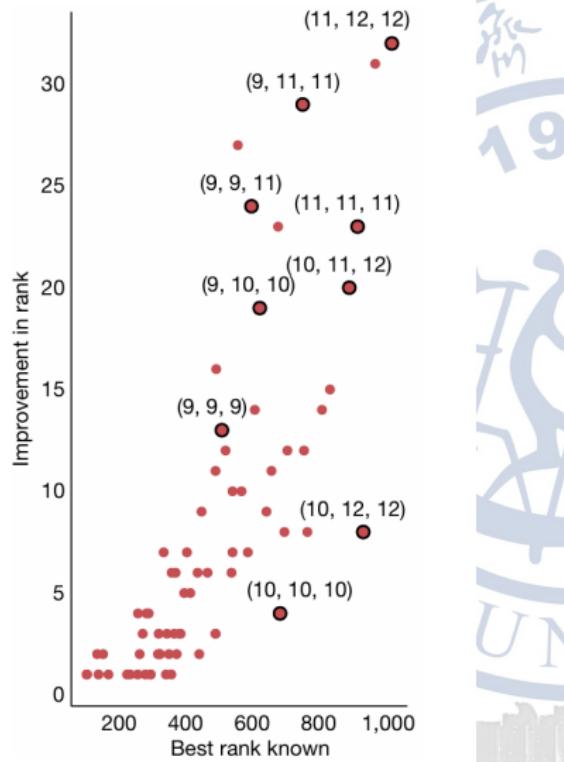
表 1: AlphaTensor 在不同矩阵尺寸下的发现

矩阵尺寸 $(n, m, k)$	现有最佳秩 (Human)	AlphaTensor
4, 4, 4	49 (Strassen <sup>2</sup> )	47
5, 5, 5	98	96
4, 5, 5	80	76

- AlphaTensor 在多种尺寸下发现了比人类已知算法更少的乘法次数。
- **注：**寻找矩阵最小的低秩分解，是 np-hard 问题。 $3 \times 3$  矩阵乘法已知的最小秩为 23，但全局最优解仍然未知，本文也未攻克。

## 理论突破：不同矩阵乘法的最小秩

Size ( $n, m, p$ )	Best method known	Best rank known	AlphaTensor rank	Modular	Standard
(2, 2, 2)	(Strassen, 1969) <sup>2</sup>	7	7	7	
(3, 3, 3)	(Laderman, 1976) <sup>15</sup>	23	23	23	
(4, 4, 4)	(Strassen, 1969) <sup>2</sup>	49	47	49	
(5, 5, 5)	(3, 5, 5) + (2, 5, 5)	98	96	98	
(2, 2, 3)	(2, 2, 2) + (2, 2, 1)	11	11	11	
(2, 2, 4)	(2, 2, 2) + (2, 2, 2)	14	14	14	
(2, 2, 5)	(2, 2, 2) + (2, 2, 3)	18	18	18	
(2, 3, 3)	(Hopcroft and Kerr, 1971) <sup>16</sup>	15	15	15	
(2, 3, 4)	(Hopcroft and Kerr, 1971) <sup>16</sup>	20	20	20	
(2, 3, 5)	(Hopcroft and Kerr, 1971) <sup>16</sup>	25	25	25	
(2, 4, 4)	(Hopcroft and Kerr, 1971) <sup>16</sup>	26	26	26	
(2, 4, 5)	(Hopcroft and Kerr, 1971) <sup>16</sup>	33	33	33	
(2, 5, 5)	(Hopcroft and Kerr, 1971) <sup>16</sup>	40	40	40	
(3, 3, 4)	(Smirnov, 2013) <sup>18</sup>	29	29	29	
(3, 3, 5)	(Smirnov, 2013) <sup>18</sup>	36	36	36	
(3, 4, 4)	(Smirnov, 2013) <sup>18</sup>	38	38	38	
(3, 4, 5)	(Smirnov, 2013) <sup>18</sup>	48	47	47	
(3, 5, 5)	(Sedoglavic and Smirnov, 2021) <sup>19</sup>	58	58	58	
(4, 4, 5)	(4, 4, 2) + (4, 4, 3)	64	63	63	
(4, 5, 5)	(2, 5, 5) $\otimes$ (2, 1, 1)	80	76	76	



## 理论突破：4\*4\*4 矩阵的低秩分解

$$\begin{pmatrix} a_{1,1} & a_{1,2} & a_{1,3} & a_{1,4} \\ a_{2,1} & a_{2,2} & a_{2,3} & a_{2,4} \\ a_{3,1} & a_{3,2} & a_{3,3} & a_{3,4} \\ a_{4,1} & a_{4,2} & a_{4,3} & a_{4,4} \end{pmatrix} \begin{pmatrix} b_{1,1} & b_{1,2} & b_{1,3} & b_{1,4} \\ b_{2,1} & b_{2,2} & b_{2,3} & b_{2,4} \\ b_{3,1} & b_{3,2} & b_{3,3} & b_{3,4} \\ b_{4,1} & b_{4,2} & b_{4,3} & b_{4,4} \end{pmatrix} = \begin{pmatrix} c_{1,1} & c_{1,2} & c_{1,3} & c_{1,4} \\ c_{2,1} & c_{2,2} & c_{2,3} & c_{2,4} \\ c_{3,1} & c_{3,2} & c_{3,3} & c_{3,4} \\ c_{4,1} & c_{4,2} & c_{4,3} & c_{4,4} \end{pmatrix}$$

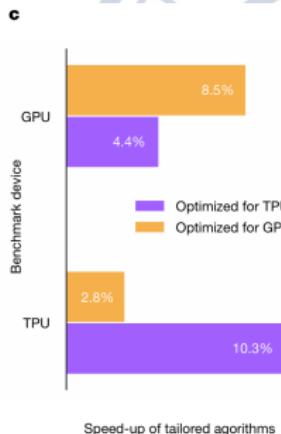
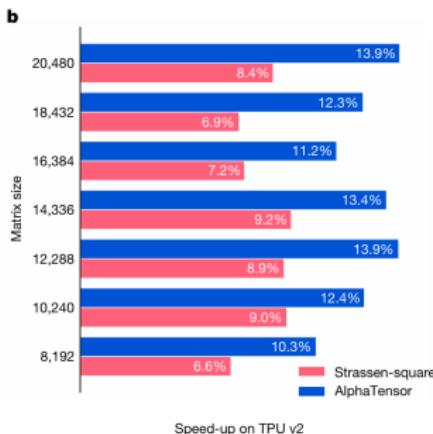
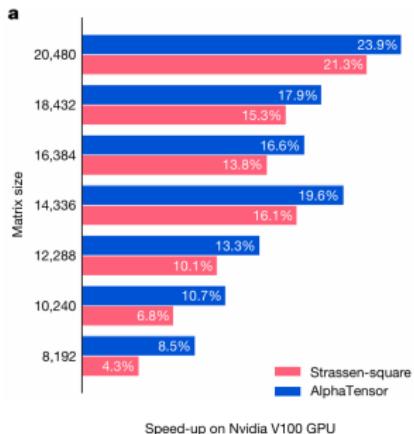
# 实际应用：硬件加速

AlphaTensor 理论上减少了计算次数，并针对特定硬件（GPU V100, TPU v3）进行优化。

## Runtime 优化

- 理论上，在大尺寸矩阵 ( $> 8192$ ) 上，AlphaTensor 发现的算法在 GPU/TPU 上均有显著加速。
- 理论上，超越了标准的 cuBLAS 库性能。
- 理论上，在矩阵尺寸增大时，加速比显著提升。
- 理论上，证明了 AI 发现的算法具有更强的加速效果。

## 实际应用：加速效果



# 消融实验

以  $4 \times 4 \times 4$  矩阵为例

消融条件	发现的秩
Without <i>synthetic demonstrations</i>	64
Without <i>selfplay</i> (supervised only)	60
Without <i>change of basis</i>	58
Without <i>signed permutations</i>	53
Without retraining on best games 10% of the time	52
Without <i>QR head</i> (using a <i>categorical head</i> )	52
<b>AlphaTensor (完整版)</b>	<b>49</b>

## 结论

完整的 AlphaTensor 达到最优性能 ( $\text{Rank} = 49$ )。移除任何组件都会导致性能下降，其中 *synthetic demonstrations* (合成演示) 的影响最大。

# 复现结果：模型训练

- 复现工作主要有两部分

  - 复现强化学习模型训练，使用 OpenTensor 开源代码
  - 复现最小的矩阵乘法次数的加速效果，使用 AlphaTensor 开源代码

```
(base) root@autodl-container-b2b911ba00-d8d87f98:~/li# conda activate opentensor
(opentensor) root@autodl-container-b2b911ba00-d8d87f98:~/li# nvidia-smi
Wed Dec 10 17:44:22 2025
+-----+
| NVIDIA-SMI 525.89.02    Driver Version: 525.89.02    CUDA Version: 12.0 |
+-----+
| GPU  Name Persistence-M  Bus-Id Disp.A  Volatile Uncorr. ECC |
| Fan  Temp  Perf Pwr:Usage/Cap | Memory-Usage | GPU-Util Compute M. |
|          %   %          | %           | % / %     MIG M. |
+-----+
| 0  Tesla V100-PCIE... On  00000000:65:04.0 Off            Off |
| N/A  32C    P0  26W / 250W |   0MiB / 32768MiB |   8% Default      N/A |
+-----+
+-----+
| Processes:
| GPU  GI CI      PID Type  Process name        GPU Memory Usage |
| ID   ID             |          |                 |          |
+-----+
| No running processes found
+-----+
```

```
(opentensor) root@autodl-container-b2b911ba00-d8d87f98:~/li/OpenTensor# python main.py --config ./config/my_conf.yaml --mode train
Preprocessing dataset...
Bit [00:00, ?it/s]
  0% |                                         | 100000/100000 [01:32<00:00, 1080.39it/s]
futureWarning: arrays to stack must be passed as a "sequence" type such as list or tuple. Support for non-sequence iterables such as generators is deprecated as of NumPy 1.16 and will raise an error in the future.
  self._prepare_examples_from_trajs()
100% |                                         | 100000/100000 [01:32<00:00, 1080.39it/s]
  0% |                                         | 0/1000000 [00:00<?, ?it/s]/root/li/OpenTensor/codes/dataset/dataset.py:64: FutureWarning: `torch.nn.utils.clip_grad_norm_` is now deprecated in favor of `torch.nn.utils.clip_grad_norm_`.
  self._clip_grad_norm_(self.net.parameters(),
  0% |                                         | 318/3000000 [04:59<763:18:28,  1.09it/s]Permute!
ainer/Trainer.py:362: FutureWarning: `torch.nn.utils.clip_grad_norm_` is now deprecated in favor of `torch.nn.utils.clip_grad_norm_`.
  torch.nn.utils.clip_grad_norm_(self.net.parameters(),
  0% |                                         | 318/3000000 [04:59<763:18:28,  1.09it/s]Permute!
/Root/li/OpenTensor/codes/trainer/Trainer.py:332: FutureWarning: arrays to stack must be passed as a "sequence" type such as list or tuple. Support for non-sequence iterables such as generators is deprecated as of NumPy 1.16 and will raise an error in the future.
  dataloader.dataset._permute_traj()
Epoch: 0 finish.
  0% |                                         | 636/3000000 [12:29<788:13:07,  1.06it/s]Permute!
Epoch: 1 finish.
  0% |                                         | 954/3000000 [19:56<763:45:14,  1.09it/s]Permute!
Epoch: 2 finish.
  0% |                                         | 1272/3000000 [27:21<778:21:31,  1.07it/s]Permute!
  0% |                                         | 1272/3000000 [27:49<1093:07:33,  1.31s/it]
```

# 复现结果：加速效果

```
(alphatensor) root@autodl-container-b2b911ba00-d8d87f98:~  
/li/pre_alphatensor# python3 benchmarking/run_gpu_benchmark.py  
Fixing GPU clock frequency to 1530 to reduce benchmarking variance...  
Done.  
Multiplying 8192 x 8192 matrices  
=====  
Strassen^2 vs `jnp.dot`: 5.35% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 8.55% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 4.99% speedup  
  
Multiplying 10240 x 10240 matrices  
=====  
Strassen^2 vs `jnp.dot`: 15.98% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 19.11% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 15.97% speedup  
  
Multiplying 12288 x 12288 matrices  
=====  
Strassen^2 vs `jnp.dot`: 14.53% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 17.09% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 14.39% speedup  
  
Multiplying 14336 x 14336 matrices  
=====  
Strassen^2 vs `jnp.dot`: 18.53% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 20.82% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 18.44% speedup
```

```
Multiplying 14336 x 14336 matrices  
=====  
Strassen^2 vs `jnp.dot`: 18.53% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 20.82% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 18.44% speedup  
  
Multiplying 16384 x 16384 matrices  
=====  
Strassen^2 vs `jnp.dot`: 17.61% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 19.60% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 17.60% speedup  
  
Multiplying 18432 x 18432 matrices  
=====  
Strassen^2 vs `jnp.dot`: 19.28% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 20.99% speedup  
AlphaTensor TPU-optimized vs `jnp.dot`: 19.18% speedup  
  
Multiplying 20480 x 20480 matrices  
=====  
Strassen^2 vs `jnp.dot`: 24.04% speedup  
AlphaTensor GPU-optimized vs `jnp.dot`: 25.84% speedup
```

# 复现结果：对照

矩阵尺寸	Strassen <sup>2</sup>		Alpha Tensor	
	复现	原文	复现	原文
8192	5.35	4.3	8.55	8.5
10240	15.98	6.8	19.11	10.7
12288	14.53	10.1	17.09	13.3
14336	18.53	16.1	20.82	19.6
16384	17.61	13.8	19.60	16.6
18432	19.28	15.3	20.99	17.9
20480	24.04	21.3	25.84	23.9

表 2: 不同算法相对于 `jnp.dot` 的加速比 (单位: %)

- 相对地, AlphaTensor 比标准库与 Strassen<sup>2</sup> 都快
- 绝对地, AlphaTensor 运算 8192 矩阵乘法的时间近 1 分钟, 运算 20480 矩阵乘法的时间近 8 分钟, 远远慢于标准矩阵乘法。

## ① 背景介绍

## ② 核心原理

## ③ 实验结果

## ④ 总结展望



# 文章局限：工业实践角度

## 硬件指令集的冲突

- 现代 GPU 均以 Tensor Cores 为计算核心，这些硬件单元在物理电路层面，针对标准的  $O(N^3)$  算法逻辑进行高度优化。
- AlphaTensor 减少了乘法操作，但将内存开销由  $O(2N)$  暴增到  $O(N^2)$ ，得不偿失。

## 数值稳定性

- 标准库倾向于选择最稳定的算法而非理论上最快的。
- AlphaTensor 通过复杂的加减法组合减少乘法，在浮点运算中容易引入精度损失，数值稳定性差。

## 结论

- Strassen 的年代，内存访问很慢，所以才开辟用数学优化矩阵乘法的道路。
- 现在内存访问快，数据处理量大，优化矩阵乘法要靠系统层面整体的优化，不能只靠数学层面的取巧。

# 文章局限：学术引用角度

- 优化矩阵计算领域，AlphaTensor 是久违的重大突破
- 强化学习领域，论文引用数逐年减少，学术热度下降。引用数主要出自综述



# 文章贡献

- **矩阵加速**

- AlphaTensor 将大矩阵乘法次数的下界从  $O(N^{2.807})$  降低到了  $O(N^{2.777})$ 。

- **AI for Science**

- 继 AlphaGo (围棋)、AlphaFold (蛋白质) 之后, DeepMind 在基础数学/理论计算机领域的突破。是强化学习的又一次成功应用。

- **未来展望**

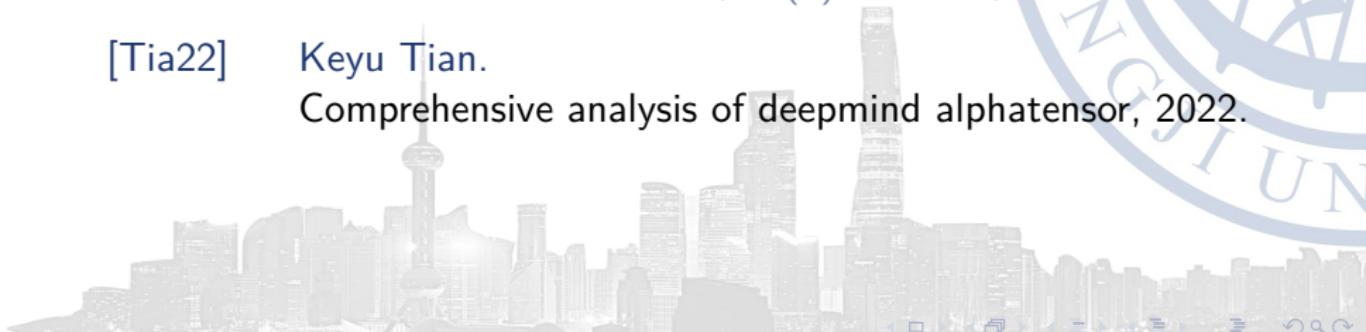
- 优化其他经典算法/理论计算机科学方法的算法流程?
- 解决其他 np-hard 问题?
- 把强化学习这种思想, 全面引入传统理工科?

# 参考资料 |

- [FBH<sup>+</sup>22] Alhussein Fawzi, Matej Balog, Aja Huang, Thomas Hubert, and Bernardino Romera-Paredes et al.  
Discovering faster matrix multiplication algorithms with reinforcement learning.  
*Nature*, 2022.
- [HL13] Christopher J. Hillar and Lek-Heng Lim.  
Most tensor problems are np-hard.  
*J. ACM*, 60(6):45, 2013.
- [SHea18] David Silver, Thomas Hubert, and Julian Schrittwieser et al.  
Mastering chess and shogi by self-play with a general reinforcement learning algorithm.  
*Science*, 2018.

# 参考资料 II

- [SL24] Yiwen Sun and Wenye Li.  
Opentensor: Reproducing faster matrix multiplication  
discovering algorithms, 2024.
- [Str69] Volker Strassen.  
Gaussian elimination is not optimal.  
*Numerische Mathematik*, 13(4):354–356, 1969.
- [Tia22] Keyu Tian.  
Comprehensive analysis of deepmind alphatensor, 2022.



# 人员分工

李致远	选题, 复现, 演讲
冯文喆	背景调研部分
魏睿	核心原理部分
宋泽顷	实验结果与总结展望部分
周启民	幻灯片

## 项目地址:

- [https://gitee.com/lychee-garden/pre\\_alphaTensor.git](https://gitee.com/lychee-garden/pre_alphaTensor.git)
- [https://gitee.com/lychee-garden/pre\\_openTensor.git](https://gitee.com/lychee-garden/pre_openTensor.git)
- [https://gitee.com/lychee-garden/alphaTensor\\_slides.git](https://gitee.com/lychee-garden/alphaTensor_slides.git)

*Thanks!*

